#4. Advanced Topic

ICEC 2017 - Deep Learning Short Course

Kim Jin Ho

How to Improve Your Model

- 지금까지는, DNN, CNN에 대한 내용과 구현하는 법에 대해 알아보았다.

- Deep Learning은 Hidden Layer를 통한 비선형 변환기법이 주이며,
  - 모델의 구조는 서로 상당히 비슷하다.

- 어떻게 하면 내 모델을 더욱 정교하게 만들 수 있을까?
  - Gradient Descent : Batch, Stochastic, Mini-Batch
  - Optimization Method : Momentum, Adaptive Gradient, RMS Prop, Adam
  - Weight Initialization : He, Xavier Initialization
  - Batch Normalization
  - Avoid Overfitting : L2 Regularization, Dropout

Gradient Descent

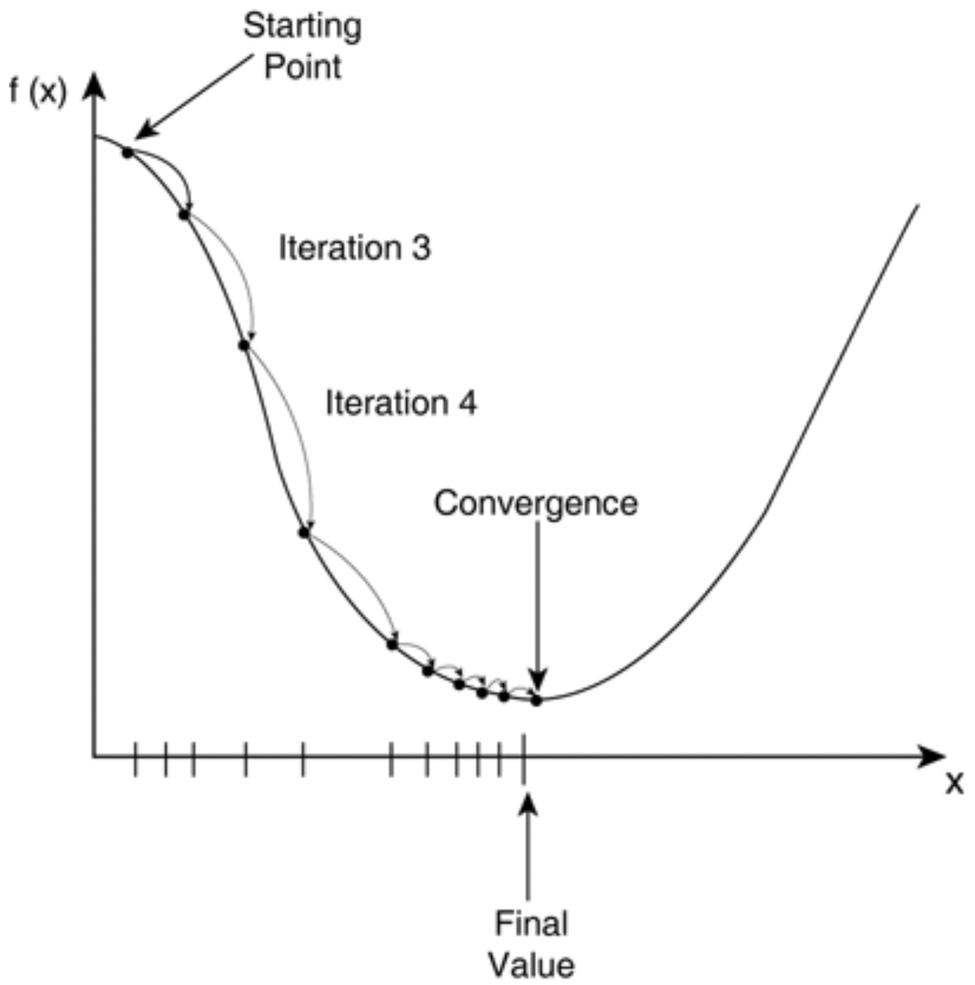

- 우리는 지금까지, 모든 데이터를 한번씩 학습하여 점차적으로 Error를 줄여가는 방법을 사용
  - 처음 시작점에서 Iteration을 반복하면서, 오차를 줄여나가 가장 오차가 적은 지점을 탐색

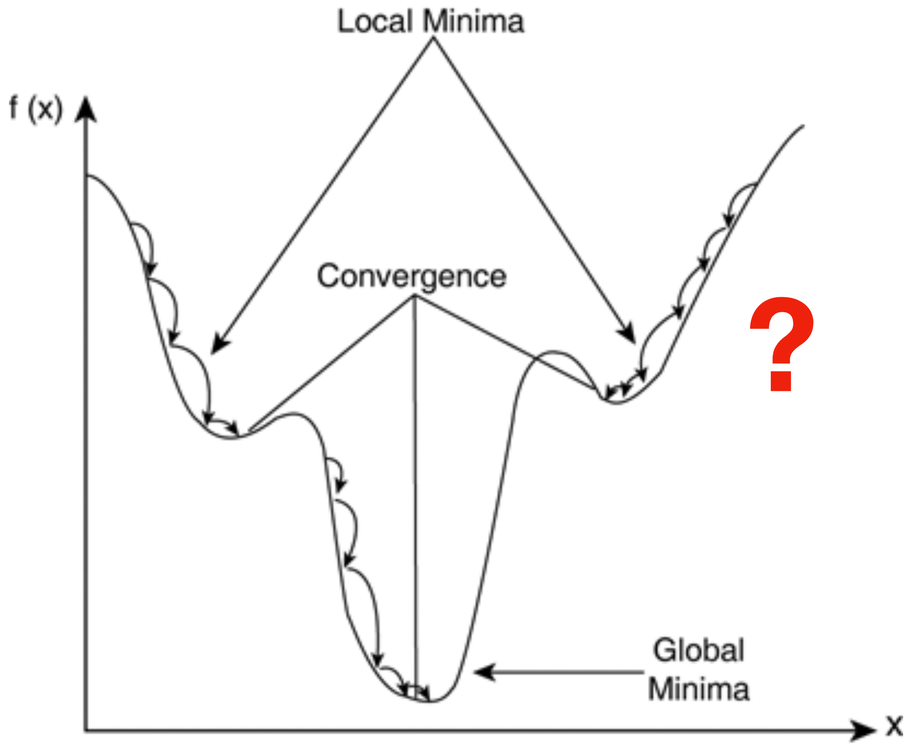

Gradient Descent

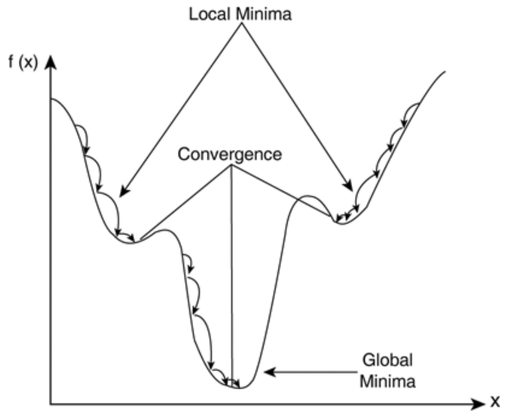

- 모든 데이터를 한번씩 학습해야, Cost Function을 올바르게 구할 수 있고, 이를 통해 지속적으로 학습해 나간다.
  - Local Optimum을 넘으려면.. 올바르게 학습할 필요가 있을까?

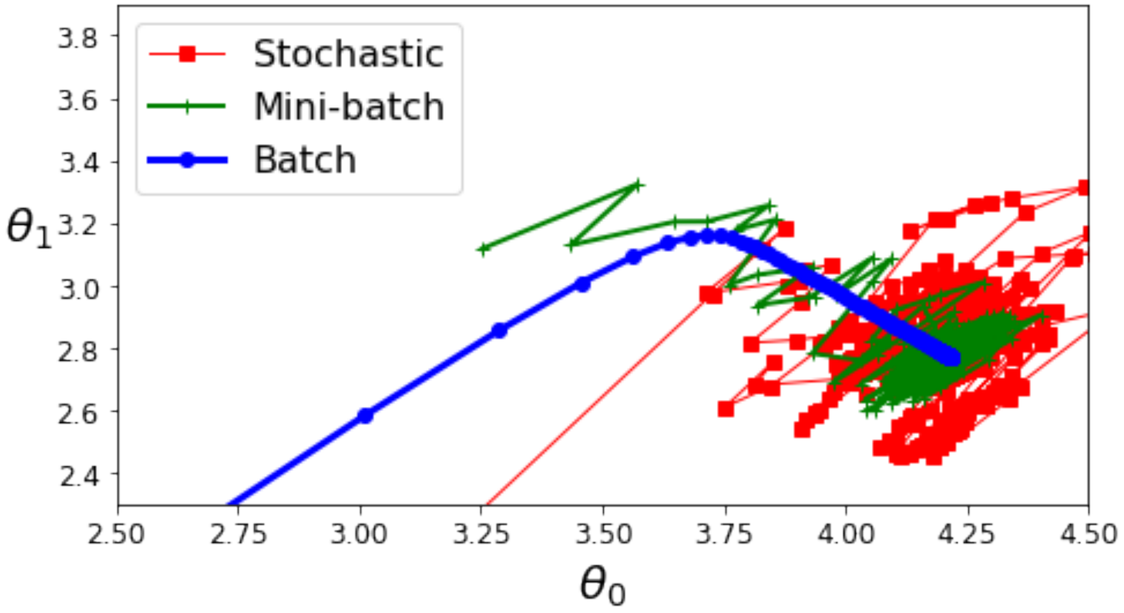

- Batch : 데이터 전체를 학습하자!
- Stochastic : 데이터를 한개만 학습한다면?
- Mini-Batch : 데이터를 조금만 학습한다면?

```
n_epochs = 10
batch_size = 100

with tf.Session() as sess:
    init.run()
    for epoch in range(n_epochs):
        for iteration in range(mnist.train.num_examples // batch_size):
            X_batch, y_batch = mnist.train.next_batch(batch_size)
            sess.run(training_op, feed_dict={X: X_batch, y: y_batch})
        acc_train = accuracy.eval(feed_dict={X: X_batch, y: y_batch})
        acc_test = accuracy.eval(feed_dict={X: mnist.test.images, y: mnis
```

Optimization Method

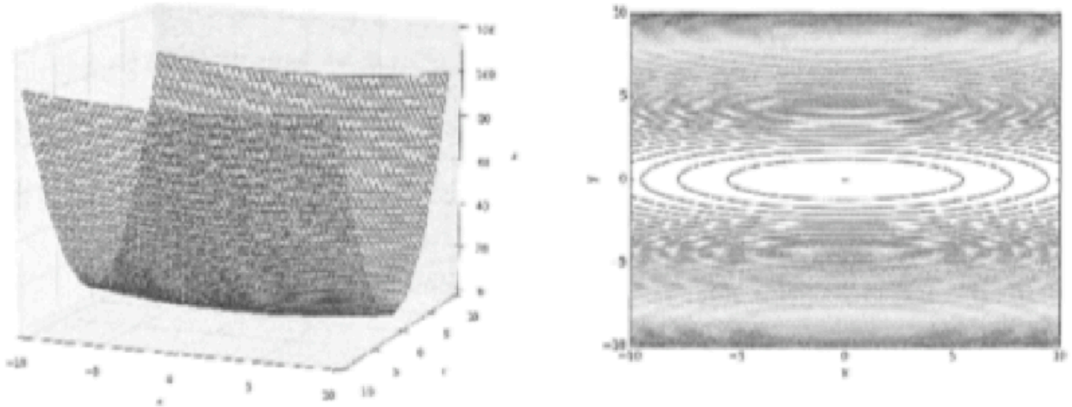

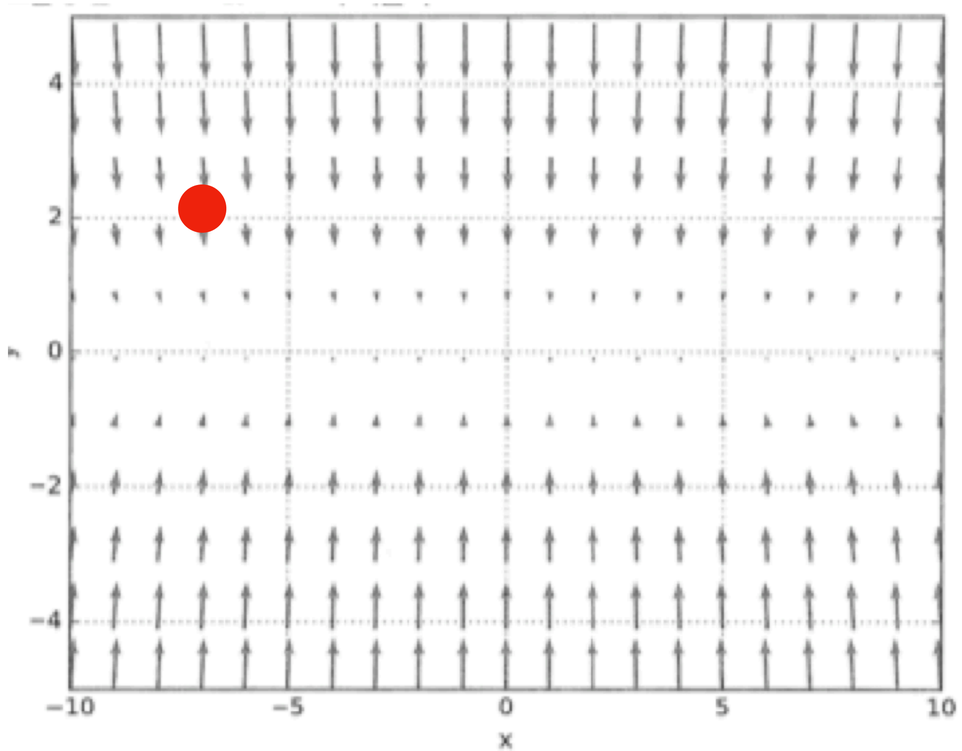

- 함수는 다음과 같은 형태를 갖는다.

$$f(x,y) = \frac{1}{20}x^2 + y^2$$

- 다음과 같은 함수의 최저점을 찾아간다면, x,y는 어떻게 변하겠는가?

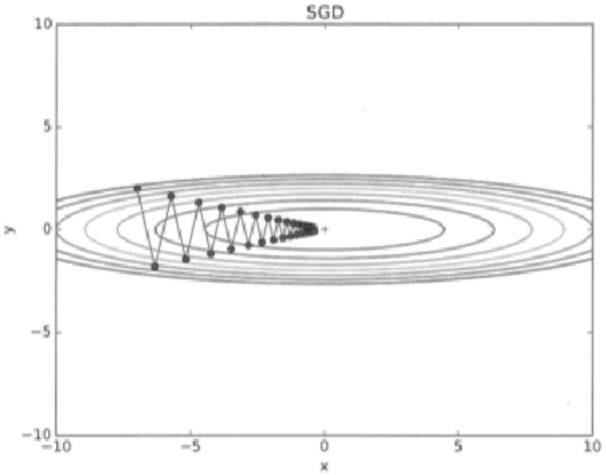

Momentum

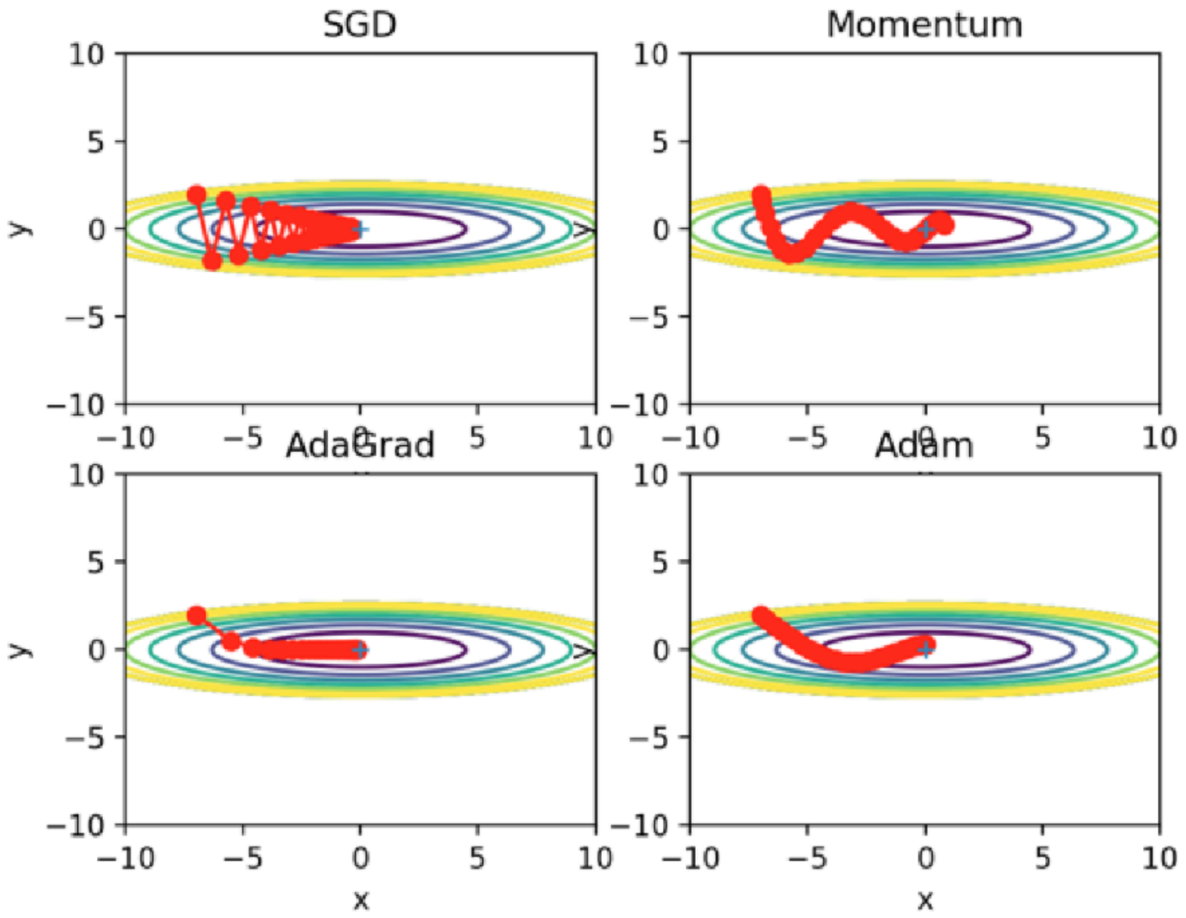

- Momentum
  - 물리학에서 사용하는 Momentum과 같은 개념으로, 움직이는 방향과 같은 방향으로 더 크게 움직인다.
- Adaptive Gradient (AdaGrad)
  - 학습이 진행됨에 따라 learning rate를 조절하는 방법
- Adam
  - Momentum과 AdaGrad의 혼합 형태

http://www.denizyuret.com/2015/03/alec-radfords-animations-for.html

Weight Initialization

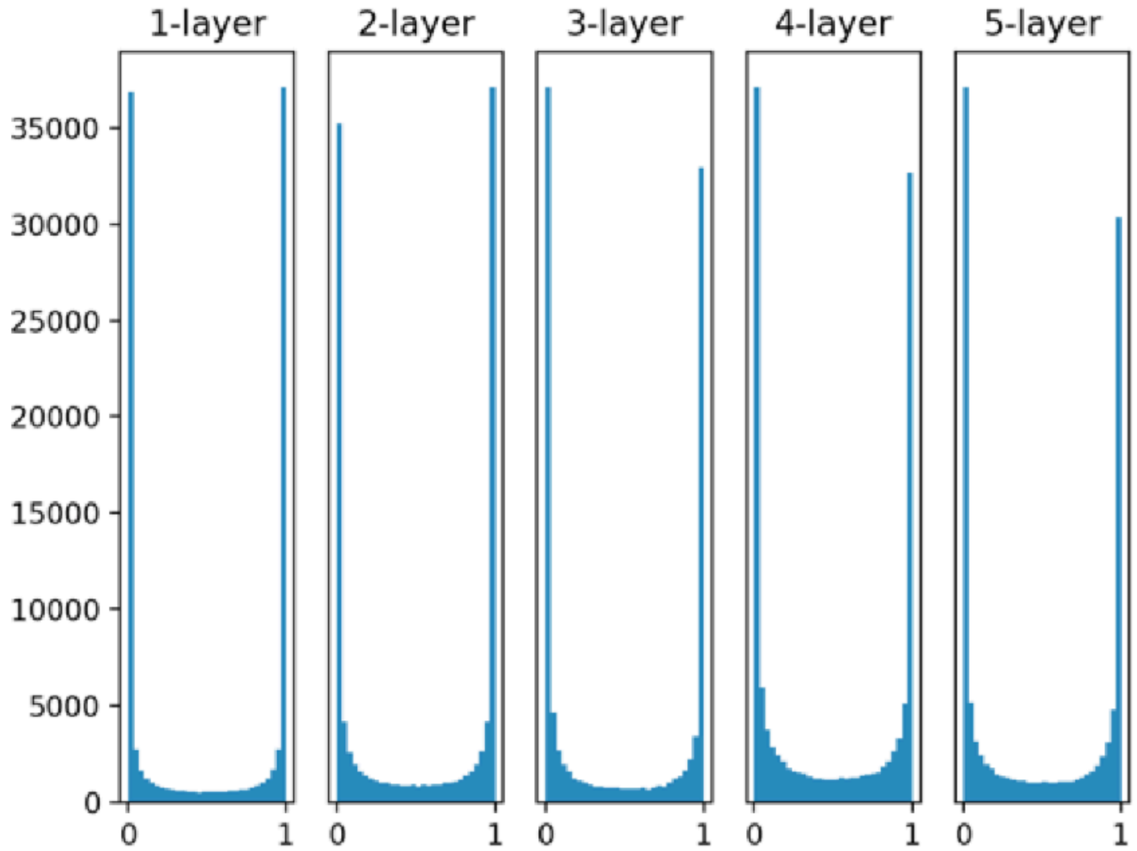

- 1000개의 input, 5 hidden layers, 100nodes
- Activation function : sigmoid
- 임의의 데이터를 넣었을 때, 나온 결과 값

- 그래프에서 볼 수 있듯이, 각 값의 분포는 0,1에 몰려있는 형태를 갖는다.
- 각 그래프에 의해 나오는 값이 0과 1을 갖는 경우 Gradient Vanishing이 발생한다.

Gradient Vanishing

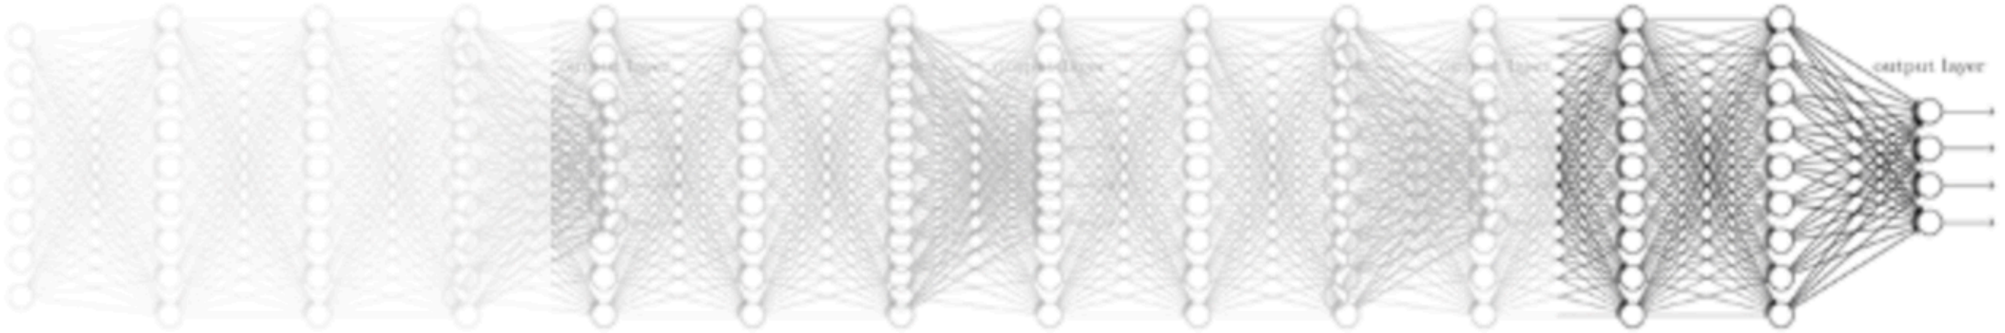

- 학습을 위한 Gradient 값이 사라져 Backpropagation을 통해 학습이 일어나지 않는 문제를 의미함.
- Hidden Layer가 너무 많이 쌓여있는 경우, 전달 값이 사라진다 : ReLU를 통해 해결!
- Node에서의 output이 0이거나 1인 경우에는?

$$\Delta w_{ij} = \frac{\partial E}{\partial w_{ij}} = \frac{\partial E}{\partial O}\frac{\partial O}{\partial h_j}\frac{\partial h_j}{w_{ij}}$$

Xavier Initialization

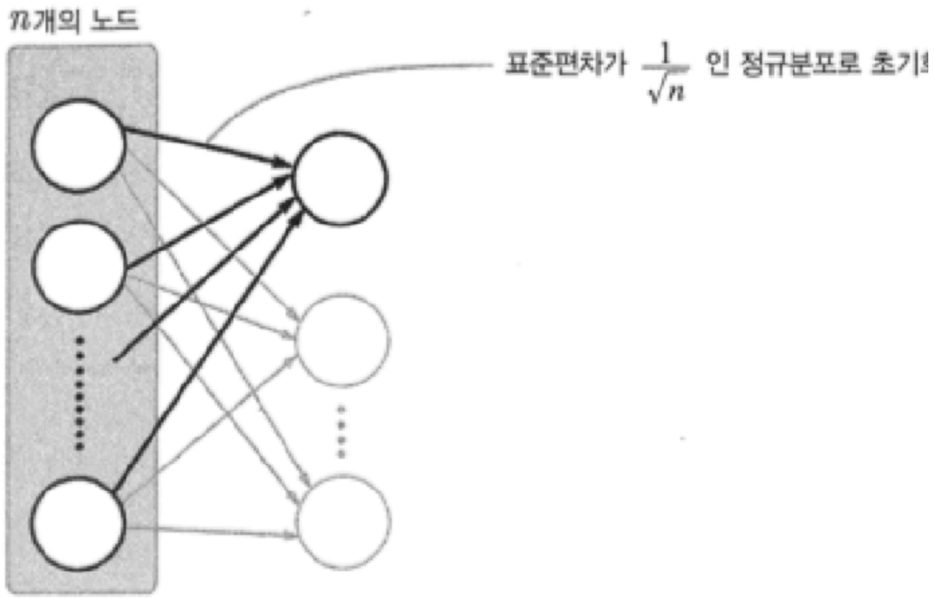

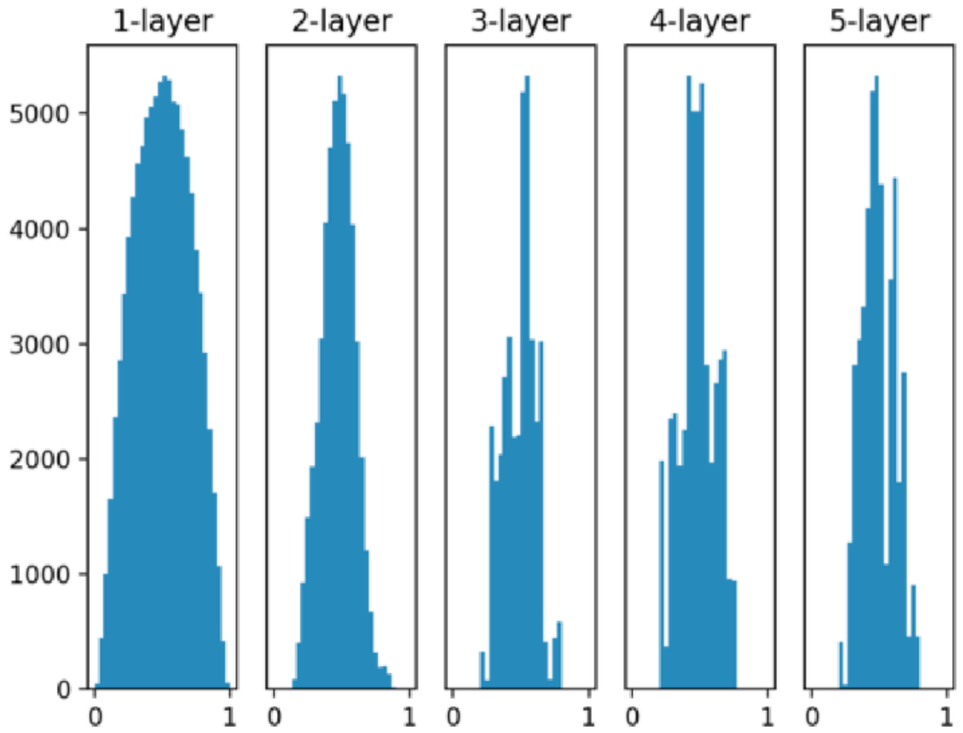

- 이전 hidden layer의 노드가 n개라면, 초기 weight값을 설정할 때, 표준편차가 $1/\sqrt{n}$ 인 정규 분포를 사용한다.

- 이와 같은 분포를 사용할 경우, 0,1에 집중되지 않은 값이 생성된다.

He Initialization

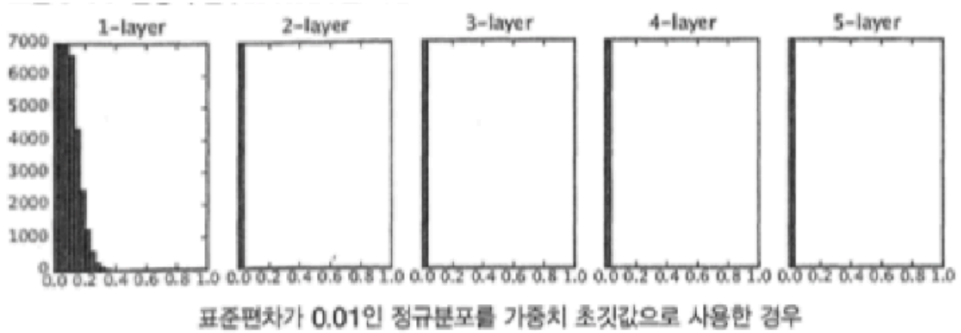

표준편차가 0.01인 정규분포를 가중치 초깃값으로 사용한 경우

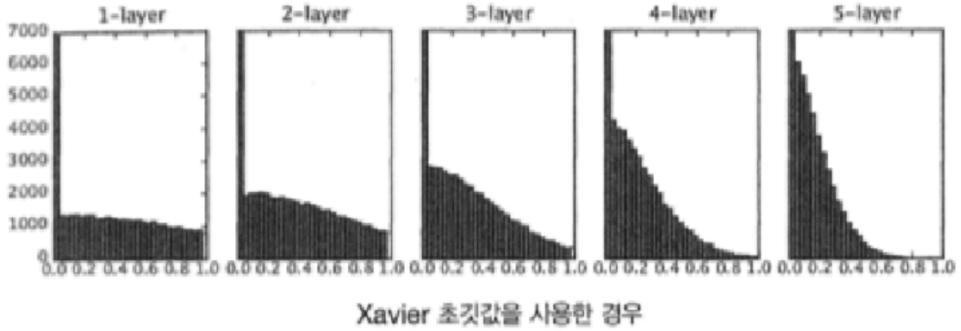

Xavier 초깃값을 사용한 경우

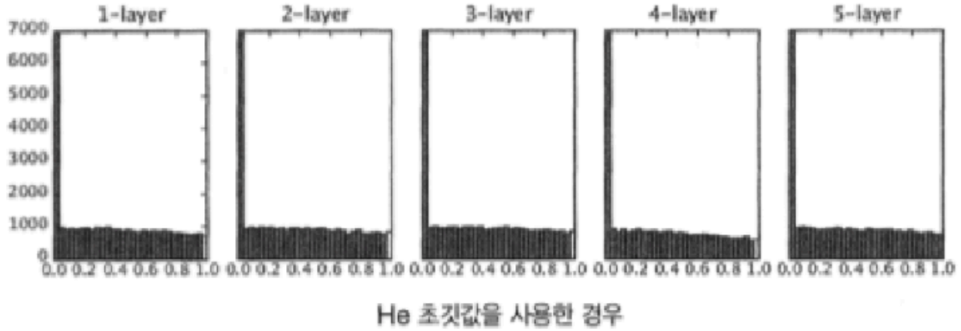

He 초깃값을 사용한 경우

- 같은 조건에서 activation function이 ReLU인 경우에는?
  - 표준편차가 $\sqrt{2/n}$인 분포로 초기값을 설정한다.

- 이 경우, Xavier초기값은 layer 5로 갈수록 output이 0에 분포되는 방면,
- He 초기값을 사용할 경우, output이 layer에 상관없이 대부분 고르게 나타난다.

Batch Normalization

- 예를 들어, hidden layer의 한 node에서 초기 학습이 잘못되어, 매우매우 큰 output이 나온다면?
  - Output의 값에 비례하여 backpropagation이 일어나므로, 다른 node들은 학습이 전혀 되지 않는다.

  - 이를 어느정도 방지하려면 어떻게 해야할까?
  - Batch Normalization은 각 층의 활성화를 적당히 퍼뜨리도록 강제화 하는 것.

$$\mu_B \leftarrow \frac{1}{m}\sum_{i=1}^{m} x_i \qquad \sigma_B^2 \leftarrow \frac{1}{m}\sum_{i=1}^{m}(x_i - \mu_B)^2 \qquad \hat{x}_i \leftarrow \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

- 복잡한 식 같지만, 평균, 분산, 정규분포화 시키는 식이다.

$$Y \leftarrow \gamma \hat{X} + \beta$$

- 위 식을 통해, weight와 input의 합을 변형한다.

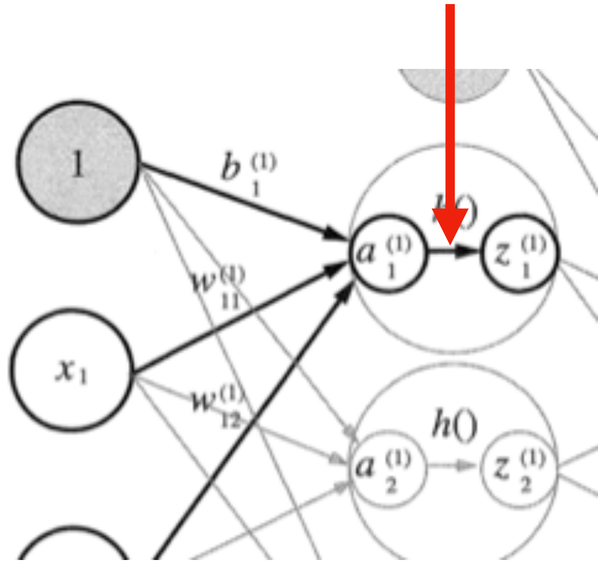

- Learning Rate가 높은 경우에 gradient가 explode/vanish하는 경우, local minima에 빠지지 않게 해준다. → **빠른학습이 가능하게 한다.**
- 자체적인 Regularization 효과가 있다. → **Dropout이 필요없다 (학습속도 향상).**

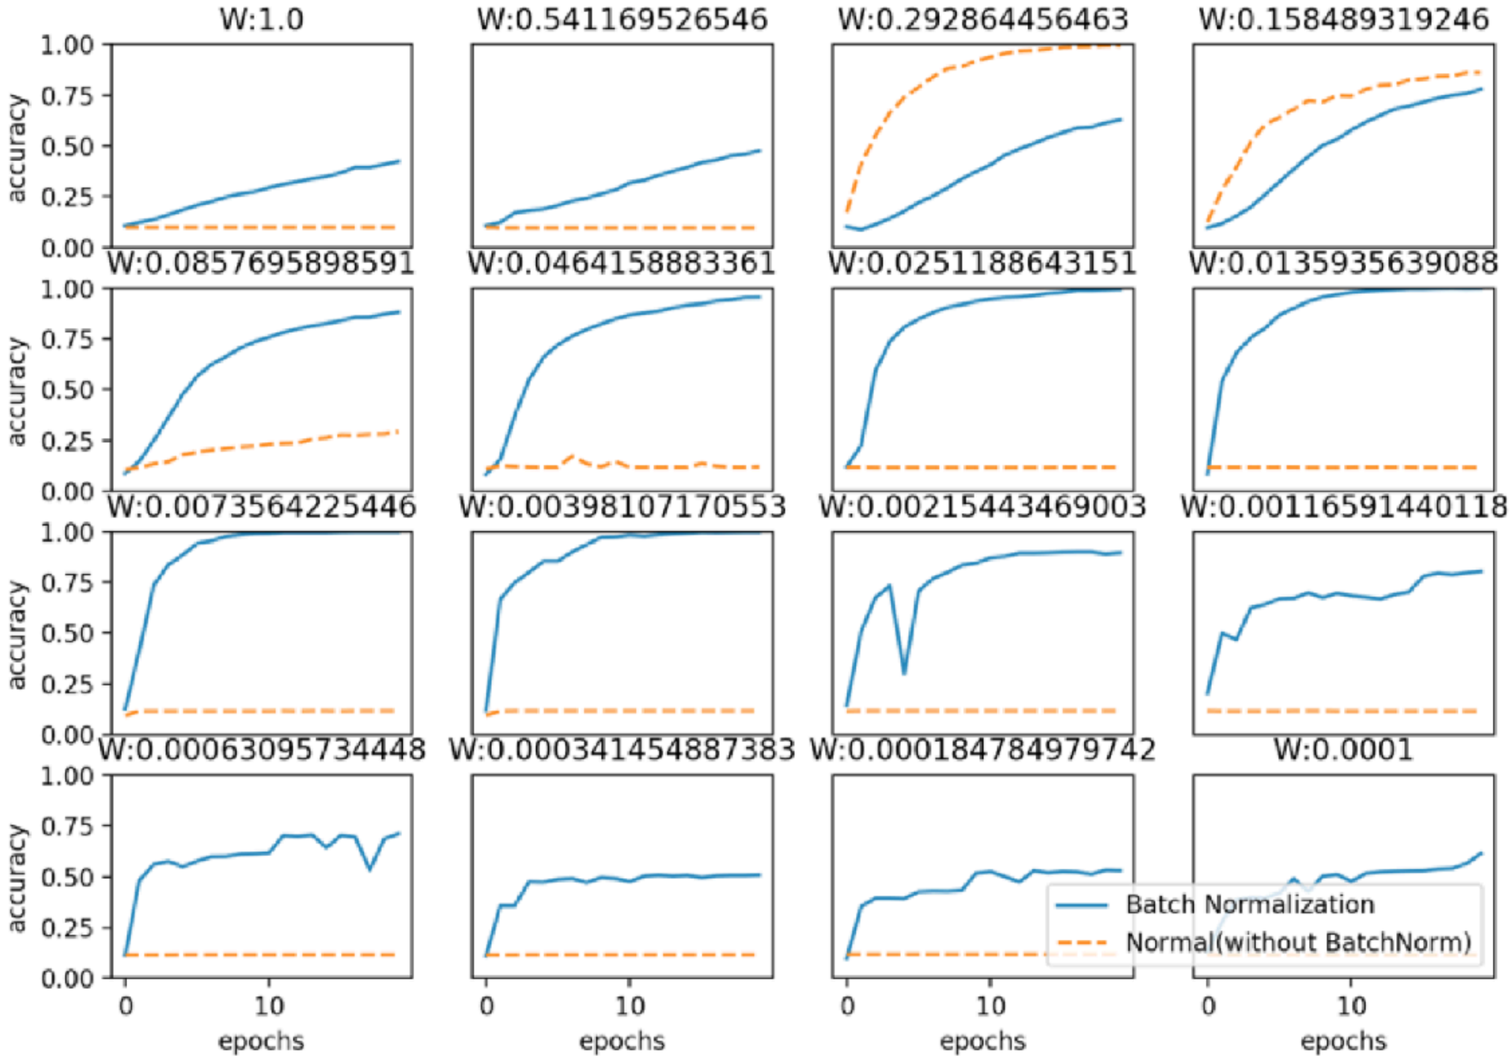

- MNIST 데이터 기준
- Weight를 특정값으로 시작한 경우,
- Batch Normalization을 쓴 경우와 쓰지 않은 경우에 대한 비교

Avoid Overfitting

- Batch Normalization은 Input이 어떤 방식으로 나오던 정규화를 해주는 방법이다.
  - 하지만, Weight가 너무 커지는 것을 막는 방법은 없을까?

$$\arg\max_{\theta} \sum_{i=1}^{m} \log(y \mid x;\theta) - \alpha R(\theta)$$

- 우리가 원하는 것은 input과 weight를 통해, 정답과 가장 근접하게 나오는 것이 목표인데, 거기에서 weight의 합을 빼게 해주면 되지 않을까?

- 이와 같은 방법을, 정규화 (Regularization) 라 한다.

L2 Regularization

- 어떤 값을 뺄 것인가?

L1 정규화항

$$R(\theta) = ||\theta||_1 = \sum_{i=1}^{n} |\theta_i|$$

L2 정규화항

$$R(\theta) = ||\theta||_2^2 = \sum_{i=1}^{n} \theta_i^2$$

Case1	Case2
1	2
1	2
1	2
1	2
4	2
4	2

- Case 1의 경우,
  - L1 = 1 + 1 + 1 + 1 + 4 + 4 = 12
  - L2 = 1 + 1 + 1 + 1 + 16 + 16 = 36
- Case 2의 경우,
  - L1 = 2 * 6 = 12
  - L2 = 4 * 6 = 24

- 큰 값을 제어하기 위해서는 L2가 효과적이다!

Python Example

- 지금까지 배웠던 DNN 코드에, 각각의 방법을 하나씩 추가하여 보자.

DNN (2 hidden layers, [300,100], Softmax function)
Mini-batch : 50
Xavier Initializer

```
0 Train accuracy: 0.9 Test accuracy: 0.9128
1 Train accuracy: 0.94 Test accuracy: 0.9291
2 Train accuracy: 0.92 Test accuracy: 0.9398
3 Train accuracy: 0.96 Test accuracy: 0.945
4 Train accuracy: 0.92 Test accuracy: 0.9513
5 Train accuracy: 0.94 Test accuracy: 0.9543
6 Train accuracy: 0.98 Test accuracy: 0.9556
7 Train accuracy: 0.96 Test accuracy: 0.9593
8 Train accuracy: 0.92 Test accuracy: 0.9625
9 Train accuracy: 0.96 Test accuracy: 0.9645
```

Gradient Descent
w/o Batch Normalization

```
0 Train accuracy: 0.98 Test accuracy: 0.9686
1 Train accuracy: 1.0 Test accuracy: 0.9749
2 Train accuracy: 0.98 Test accuracy: 0.9771
3 Train accuracy: 1.0 Test accuracy: 0.9803
4 Train accuracy: 1.0 Test accuracy: 0.9808
5 Train accuracy: 0.98 Test accuracy: 0.9815
6 Train accuracy: 0.98 Test accuracy: 0.9822
7 Train accuracy: 1.0 Test accuracy: 0.9829
8 Train accuracy: 0.98 Test accuracy: 0.9833
9 Train accuracy: 1.0 Test accuracy: 0.9799
```

Adam Optimizer
w/ Batch Normalization

Reference

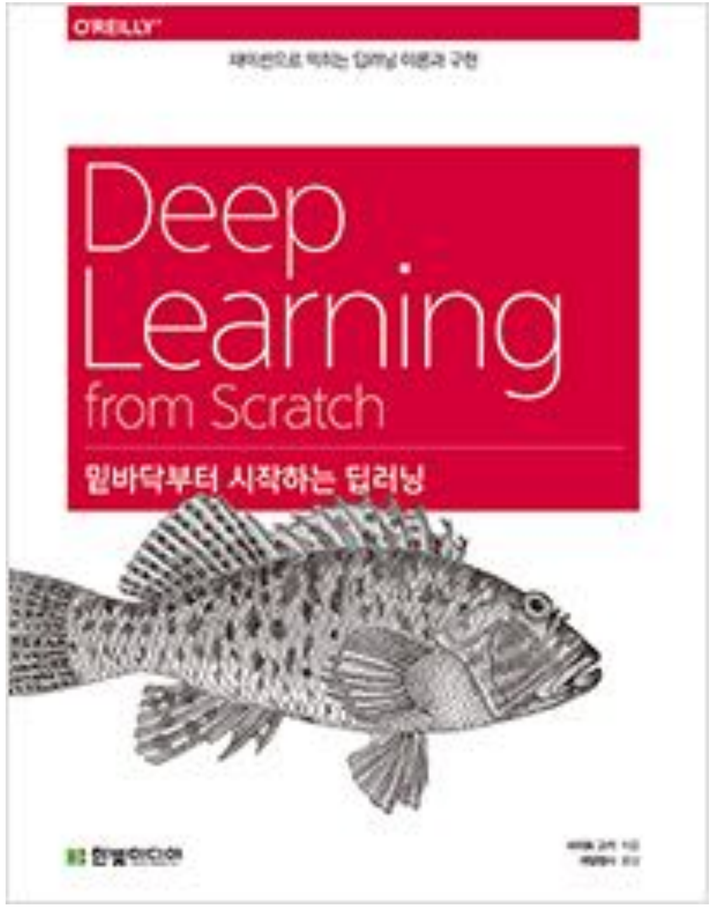

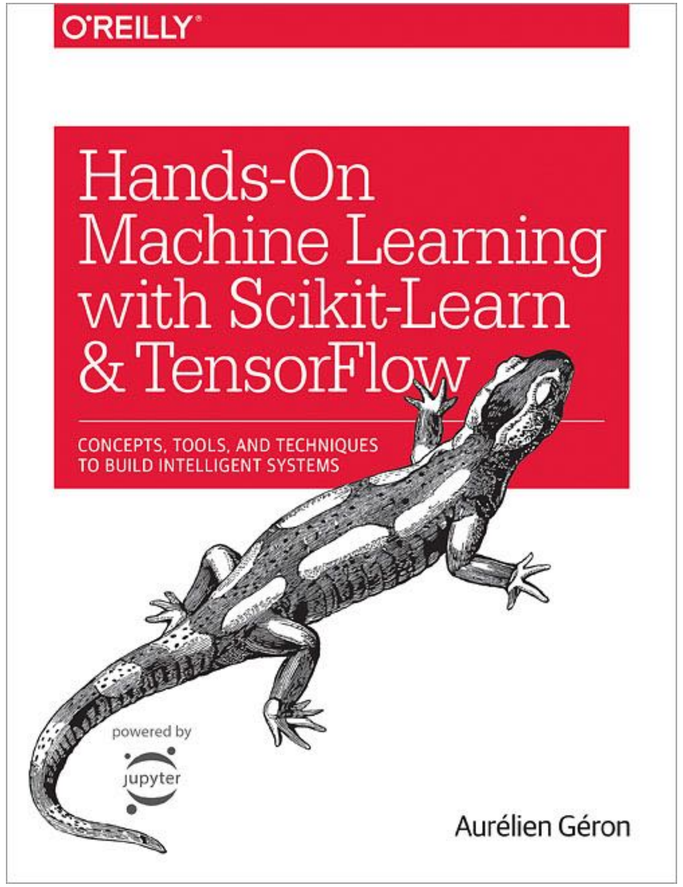

http://www.deeplearningbook.org/